

TỔNG KẾT TIẾN ĐỘ DỰ ÁN

Phát hiện URL Lừa đảo bằng Machine Learning và Chrome Extension

Ngày cập nhật: 05/04/2026 | Trần Duy Thái

I. THÔNG TIN DỰ ÁN

1.1. Tên đề tài

Phát hiện URL lừa đảo sử dụng Machine Learning kết hợp Chrome Extension để cảnh báo người dùng theo thời gian thực.

1.2. Mục tiêu

Xây dựng hệ thống phân loại URL thành hai lớp: hợp lệ và lừa đảo. Hệ thống hoạt động offline trên trình duyệt Chrome, không cần kết nối mạng ngoài. Mô hình được chọn là XGBoost với F1-Score đạt 98,95%.

1.3. Dữ liệu sử dụng

Bộ dữ liệu gồm 651.191 mẫu URL (423.705 hợp lệ, 227.486 lừa đảo) lấy từ các nguồn: PhishTank, OpenPhish, APWG và Tranco Top 1 Million.

1.4. Công nghệ sử dụng

Thành phần	Công cụ / Thư viện
Phân tích dữ liệu	Python, Pandas, Matplotlib, Seaborn
Máy học	Scikit-learn, XGBoost, LightGBM, imbalanced-learn (SMOTE)
Báo cáo	Node.js (docx), Jupyter Notebook
Trình duyệt	Chrome Extension Manifest V3, JavaScript

1.5. File đầu ra

Báo cáo chính: BaoCao_DACS_TranDuyThai.docx

Mô hình đã tối ưu: data/xgboost_model_tuned.json (402,4 KB)

Notebook phân tích: 03_eda_and_model.ipynb

II. NHỮNG GÌ ĐÃ HOÀN THÀNH

2.1. Thu thập và xử lý dữ liệu

Đã thu thập 651.191 URL từ 4 nguồn khác nhau. Quá trình xử lý bao gồm: kiểm tra giá trị null, loại trừ trùng lặp và chuẩn hóa định dạng URL.

2.2. Trích xuất đặc trưng (Feature Engineering)

Đã trích xuất 30 đặc trưng từ URL, bao gồm:

1. Đặc trưng độ dài: độ dài URL, hostname, path, query, số dấu chấm
2. Đặc trưng ký tự: số lượng dấu gạch nối, gạch chéo, @, ?, =, &, #, %
3. Đặc trưng cấu trúc: có www, có port, là địa chỉ IP, số subdomain
4. Đặc trưng nội dung: có HTTPS, có tên nhãn hiệu nổi tiếng

2.3. Phân tích khám phá (EDA)

Đã thực hiện EDA đầy đủ: biểu đồ phân phối nhãn, ma trận tương quan đặc trưng, so sánh giá trị trung bình giữa hai lớp. Dữ liệu mất cân bằng (65,1% hợp lệ, 34,9% lừa đảo), xử lý bằng SMOTE sau khi tách tập huấn luyện.

2.4. Huấn luyện và đánh giá mô hình

Đã huấn luyện 6 mô hình: Logistic Regression, Random Forest, XGBoost, LightGBM, Decision Tree và SVM. SVM có F1 cao nhất (0,9932) nhưng không xuất được sang JSON. XGBoost được chọn để triển khai vì hỗ trợ JSON.

2.5. Tối ưu hóa siêu tham số

Đã thực hiện RandomizedSearchCV với 30 lần thử, 5-fold CV, mục tiêu F1. Tham số tốt nhất: `n_estimators=400`, `max_depth=6`, `learning_rate=0,1`. Sau tối ưu: $F1 = 0,9895$, kích thước mô hình giảm từ 468 KB xuống 402,4 KB.

2.6. Báo cáo

Đã hoàn thiện báo cáo gồm 4 chương: Giới thiệu, Cơ sở lý thuyết, Phát triển hệ thống và Tổng kết. File được tạo tự động bằng Node.js.

III. HƯỚNG ĐI TIẾP THEO VÀ CHƯA LÀM ĐƯỢC

3.1. Xây dựng Chrome Extension (Tuần 8-9)

Cần xây dựng 6 file chính cho Extension:

1. manifest.json: Cấu hình Manifest V3, khai báo quyền truy cập và service worker
2. feature_extractor.js: Trích xuất 30 đặc trưng từ URL hiện tại
3. xgboost_predictor.js: Tải model JSON và thực hiện dự đoán offline
4. content.js: Hiển thị cảnh báo trên trang web khi phát hiện lừa đảo
5. popup.html + popup.js: Giao diện popup hiển thị kết quả phân tích
6. background.js: Service worker quản lý trạng thái Extension

Lưu ý: cấu trúc JSON của XGBoost là mảng phẳng (flat arrays). Thuật toán duyệt cây dùng: left_children, right_children, split_indices, split_conditions, base_weights.

3.2. Hoàn thiện báo cáo (Tuần 10)

Cần bổ sung mục 3.6 sau khi có demo Extension. Các bước:

1. Chụp ảnh màn hình minh họa Extension đang hoạt động
2. Viết mô tả luồng xử lý từ URL đến kết quả phân tích
3. Kiểm tra lại toàn bộ báo cáo về định dạng và số liệu
4. Xuất file BaoCao_DACS_TranDuyThai.docx bản cuối

3.3. Kiểm thử và demo

Kiểm thử trên 3 loại URL: lừa đảo thực tế, hợp lệ phổ biến và URL biến thể nhại. Ghi lại kết quả để bổ sung vào báo cáo.

IV. KẾT QUẢ MÔ HÌNH

Bảng 4.1. So sánh hiệu suất 6 mô hình

Mô hình	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0,9212	0,8723	0,8271	0,8491
Decision Tree	0,9701	0,9512	0,9441	0,9476
Random Forest	0,9851	0,9798	0,9751	0,9774
LightGBM	0,9843	0,9768	0,9771	0,9769
XGBoost (mặc định)	0,9857	0,9792	0,9914	0,9852
SVM	0,9940	0,9921	0,9944	0,9932

Ghi chú: SVM có F1 cao nhất nhưng không xuất được sang JSON cho Extension. XGBoost được chọn để triển khai.

Bảng 4.2. XGBoost trước và sau tối ưu hóa

Chỉ số	Trước tối ưu	Sau tối ưu
F1-Score	0,9852	0,9895
Accuracy	0,9857	0,9900
Precision	0,9792	0,9858
Recall	0,9914	0,9932
Kích thước mô hình	468 KB	402,4 KB
Số cây	300	400